



الجامعة السورية الخاصة
كلية هندسة الحاسوب والمعلوماتية
قسم الذكاء الاصطناعي وعلوم البيانات

كشف سرطان الفم باستخدام تقنيات التعلم الآلي

إعداد

ليث الابراهيم

إشراف

م.فرح فارس

د.ماجدة بكور

العام الدراسي

(2026/8)

إقرار المشرف

أشهد بأن إعداد هذا المشروع الموسوم.....

.....

والمعد من قبل الطالب: ليث الابراهيم

تحت إشرافي في قسم الذكاء الصناعي و علوم البيانات في كلية
هندسة المعلوماتية وهو جزء من متطلبات نيل الإجازة في هندسة
الذكاء الصناعي و علوم البيانات

المرتبة العلمية..... الاسم.....

التوقيع: التاريخ

المرتبة العلمية..... الاسم.....

التوقيع: التاريخ

المخلص

يهدف هذا المشروع إلى التصدي لتحدي طبي بالغ الأهمية يتمثل في الكشف المبكر عن سرطان الخلايا الحشرية الفموية (Oral Squamous Cell Carcinoma - OSCC) ، والذي يُعد من أكثر أنواع سرطانات الفم شيوعًا وخطورة، خاصةً في حال تأخر اكتشافه. ويُعد الكشف المبكر عاملاً أساسياً في تحسين فرص العلاج وتقليل المضاعفات ومعدلات الوفيات المرتبطة بالمرض.

تمثلت الغاية الرئيسية للمشروع في تطوير نظام ذكي يعتمد على تقنيات الذكاء الاصطناعي والتعلم العميق ورؤية الحاسوب لتحليل الصور الطبية والمساعدة في التمييز بين الأنسجة الطبيعية والأنسجة المصابة بسرطان الفم، بما يساهم في تسريع عملية الكشف ودعم الأطباء في اتخاذ القرارات التشخيصية.

تم تدريب واختبار مجموعة من نماذج التعلم العميق المختلفة بهدف دراسة قدرتها على تصنيف صور خلايا الفم، ومن أبرزها نموذج InceptionV3 القائم على التعلم بالنقل (Transfer Learning) ، ونموذج AlexNet القائم على الشبكات العصبية التلافيفية (CNN) ، بالإضافة إلى نموذج Vision Transformer (ViT) الحديث لمعالجة الصور. كما تم تطوير نموذج ViT متعدد الوسائط (Multimodal ViT) يجمع بين المعلومات المستخرجة من الصور المجهزية والبيانات السريرية للمريض، والتي تشمل العمر والجنس والتدخين والكحول ومضغ التبغ والتاريخ العائلي. ويعتمد هذا النموذج على استخراج الميزات البصرية من الصور باستخدام ViT ثم دمجها مع الميزات السريرية قبل إجراء التصنيف النهائي.

اعتمد المشروع على مجموعة بيانات مكونة من 4946 صورة طبية مصنفة إلى فئتين، هما OSCC بعدد 2511 صورة و Normal بعدد 2435 صورة. وتم إجراء عمليات معالجة مسبقة للصور، وتقسيم البيانات إلى مجموعات التدريب والتحقق والاختبار، بالإضافة إلى استخدام تقنيات زيادة البيانات في بعض مراحل التدريب بهدف تحسين قدرة النماذج على التعميم وتقليل مشكلة فرط التخصيص.

أظهرت النماذج المستخدمة أداءً جيداً في مهمة تصنيف صور سرطان الفم، حيث حقق نموذج AlexNet في نتائج الاختبار دقة بلغت حوالي 91.52%، واستدعاءً بلغ حوالي 96.02%، ودقة تصنيف (Precision) بلغت حوالي 88.28%، ودرجة F1 بلغت حوالي 91.98%. كما تم تطوير نموذج ViT متعدد الوسائط وتدريبه باستخدام مجموعة من تقنيات تحسين التدريب، مثل Adam Optimizer و Early Stopping و ReduceLROnPlateau و Class Weights، مع تقييمه باستخدام Accuracy و AUC و Precision و Recall ومصفوفة الالتباس.

ولتعزيز النظام التشخيصي وتوفير تحليل أكثر شمولاً، تم دمج نماذج إضافية ضمن واجهة التطبيق، منها MobileNetV2 كنموذج خفيف الوزن للتصنيف، و YOLOv8 للكشف وتحديد مواقع الخلايا أو النوى المشبوهة داخل الصور المجهرية. وبذلك أصبح النظام قادراً على الجمع بين التصنيف، وتحليل البيانات السريرية، وتحديد البصري للمناطق المشبوهة، مما يوفر إطاراً متكاملًا لدعم الكشف المبكر عن سرطان الفم.

تشير النتائج والتجارب التي تم تنفيذها إلى إمكانية الاستفادة من تقنيات التعلم العميق والرؤية الحاسوبية في تطوير أدوات مساعدة للكشف عن سرطان الفم، مع التأكيد على أن النظام المقترح يمثل أداة لدعم القرار الطبي وليس بديلاً عن الطبيب المختص أو الفحص والتشخيص السريري النهائي.

الفهرس

3.....	الملخص
11.....	قائمة الجداول
12.....	قائمة الأشكال
13.....	قائمة المصطلحات

الفصل الأول: المقدمة

16.....	1.1 تمهيد عن المشروع
17.....	1.2 المشكلة التي يحلها المشروع
19.....	1.3 أهداف المشروع
20.....	1.4 بنية تقرير المشروع

الفصل الثاني: الدراسة النظرية

22.....	2.1 مقدمة
22.....	2.2 سرطان الخلايا الحرشفية الفموية (OSCC)
22.....	2.2.1 تعريف المرض
22.....	2.2.2 عوامل الخطر
23.....	2.3 الذكاء الاصطناعي في المجال الطبي
24.....	2.4 التعلم العميق (Deep Learning)
25.....	2.5 الشبكات العصبية التلافيفية (CNN)
26.....	2.6 نموذج AlexNet

27.....	2.7 نموذج InceptionV3
27.....	2.8 التعلم بالنقل (Transfer Learning)
28.....	2.9 نموذج Vision Transformer (ViT)
28.....	2.10 البيانات السريرية (Clinical Data)
29.....	2.11 التعلم متعدد الوسائط (Multimodal Learning)
29.....	2.12 نموذج MobileNet
30.....	2.13 نموذج YOLOv8
30.....	2.14 تفسير النماذج (Explainable AI)
31.....	2.16 مقاييس التقييم

الفصل الثالث: الدراسات المرجعية

35.....	3.1 مقدمة
35.....	3.2 الدراسة الأولى: تحليل الصور النسيجية المرضية لتصنيف سرطان الفم باستخدام SVM
36.....	3.3 الدراسة الثانية: مراجعة استخدام التعلم الآلي في تحليل صور سرطان الفم
36.....	3.4 الدراسة الثالثة: استخدام AlexNet و Transfer Learning
37.....	3.5 الدراسة الرابعة: نموذج Deep Learning للكشف عن OSCC
38.....	3.6 الدراسة الخامسة EfficientNetB3: للكشف عن OSCC
38.....	3.7 الدراسة السادسة: المراجعة المنهجية للتعلم العميق في سرطان الفم
39.....	3.8 الدراسة السابعة: المراجعة والتحليل التجميعي لـ OSCC
39.....	3.9 الدراسة الثامنة Vision Transformer: قابل للتفسير لسرطان الفم

40.....	3.10 الدراسة التاسعة Transformer Hybrid :للكشف عن OSCC
41.....	3.11 الدراسة العاشرة Deep Learning Multimodal :لسرطان الفم
42.....	3.12 الدراسة الحادية عشرة AI Multimodal :للتشخيص المبكر
43.....	3.13 الدراسة الثانية عشرة YOLOv8 :للكشف عن سرطان الفم
44.....	3.14 الدراسة الثالثة عشرة: مقارنة خمسة نماذج CNN
45.....	3.15 الدراسة الرابعة عشرة: مشكلة التعميم واختلاف صبغة الصور
45.....	3.16 جدول المقارنة بين الدراسات السابقة والمشروع المقترح

الفصل الرابع: منهجية العمل

49.....	4.1 مقدمة
49.....	4.2 بيئة العمل والأدوات المستخدمة
49.....	4.2.1 لغة Python
49.....	4.2.2 Google Colab
49.....	4.2.3 TensorFlow و keras
50.....	4.2.4 Keras Hub / Vision Transformer
50.....	4.2.5 OpenCV
50.....	4.2.6 NumPy
51.....	4.2.7 Pandas
51.....	4.2.8 Scikit-learn
51.....	4.2.9 Matplotlib

52.....	YOLOv8 وUltralytics 4.2.10
52.....	Roboflow 4.2.11
52.....	Streamlit 4.2.12
53.....	4.3 مخطط العمل العام للنظام
55.....	4.4 مجموعة البيانات
55.....	4.5 تجهيز البيانات ومعالجتها
55.....	4.5.1 إنشاء DataFrame
55.....	4.5.2 التحقق من البيانات
55.....	4.5.3 تغيير حجم الصور
56.....	4.6 تقسيم البيانات
56.....	4.7 زيادة البيانات Data Augmentation
57.....	4.8 تدريب نماذج التصنيف
57.....	4.9 نموذج AlexNet
58.....	4.10 نموذج InceptionV3
59.....	4.11 نموذج Vision Transformer
59.....	4.12 نموذج ViT متعدد الوسائط Multimodal ViT
60.....	4.13 معالجة البيانات السريرية
60.....	4.14 نموذج MobileNetV2
60.....	4.15 نموذج YOLOv8

61	4.16 آلية دمج النماذج.....
61	4.17 تقنيات تحسين التدريب.....
61	4.18 تقييم النماذج.....
62	4.19 تفسير قرارات النموذج.....
63	4.20 واجهة النظام.....
64	4.21 خلاصة الفصل.....

الفصل الخامس: معايير التقييم والنتائج

66	5.1 مقدمة.....
66	5.2 إعداد التجارب.....
67	5.3 نتائج نموذج AlexNet.....
67	5.3.1 مصفوفة الالتباس.....
68	5.4 Classification Report لنموذج AlexNet.....
69	5.5 منحنيات تدريب AlexNet.....
70	5.6 نتائج نموذج InceptionV3.....
72	5.7 نتائج نموذج Vision Transformer (ViT).....
73	5.7.1 مصفوفة الالتباس.....
74	5.7.2 منحنيات التدريب.....
75	5.8 نتائج النموذج متعدد الوسائط ViT M.....
76	5.9 نتائج نموذج MobileNet.....

78	5.10 نتائج نموذج YOLOv8
80	5.11 نتائج النظام التطبيقي النهائي
81	5.12 التفسير البصري للنتائج
81	5.13 نقاط القوة

الفصل السادس: الخلاصة والتوصيات

84	6.1 مقدمة
84	6.2 الخلاصة
86	6.3 أهم ما تم تحقيقه
87	6.4 التوصيات
88	6.5 الأعمال المستقبلية
88	6.5.1 استخدام نماذج Transformer أكثر تطوراً
89	6.5.2 تطوير النموذج متعدد الوسائط
89	6.5.3 استخدام نماذج الكشف والتقسيم
89	6.5.4 تطوير نظام دعم قرار طبي
90	6.5.5 تطبيق النظام على الأجهزة المحمولة
90	6.5.6 إجراء اختبار خارجي للنظام
91	6.5.7 تطوير واجهة النظام
91	6.6 الخلاصة النهائية
93	<u>المراجع</u>

قائمة الجداول

الجدول 2.1:المقارنة بين الدراسات المرجعية.....	47
الجدول 4.1: توصيف الداتا سيت.....	55
الجدول 4.2:تقسيم البيانات والغرض منه.....	56
الجدول 5.1: مصفوفة الالتباس	67
الجدول 5.2:تقرير النتائج لنموذج AlexNet.....	68
الجدول 5.3: تقرير النتائج لنموذج InceptionV3.....	72
الجدول 5.4: تقرير النتائج لنموذج MobileNet	76

قائمة الاشكال

الشكل 1.1: سرطان الفم__ قرحة حمراء	23
الشكل 1.2: مصفوفة الارتباك	32
الشكل 4.1: بنية العمل بشكل عام	54
الشكل 3.4: نموذج CNN	58
الشكل 5.1: مصفوفة الالتباس لنموذج AlexNet	69
الشكل 5.2: منحنيات Accuracy و Loss لنموذج AlexNet	70
الشكل 5.3: Confusion Matrix لنموذج InceptionV3	71
الشكل 5.4: منحنى Accuracy و Loss لنموذج InceptionV3	72
الشكل 5.5: Confusion Matrix لنموذج ViT	74
الشكل 5.6: Accuracy و Loss لنموذج ViT	74
الشكل 5.7: Precision و Recall لنموذج ViT	75
الشكل 5.8: Confusion Matrix لنموذج MobileNet	77
الشكل 5.9: Accuracy و Loss لنموذج MobileNet	78
الشكل 5.10: نتائج الكشف باستخدام YOLOv8	79
الشكل 5.11: نتائج التشخيص الشامل	81

قائمة المصطلحات

الرقم	المصطلح بالعربية	المصطلح بالإنجليزية	الاختصار
1	شبكات عصبونية	Neural Networks	NN
2	رؤية حاسوبية	Computer Vision	CV
3	معالجة اللغات الطبيعية	Natural Language Processing	NLP
4	سرطان الخلايا الحشرية الفموي	Oral Squamous Cell Carcinoma	OSCC
5	طبيعي (سليم)	Normal	—
6	الذكاء الصناعي	Artificial Intelligence	AI
7	الشبكة العصبية التلافيفية	Convolutional Neural Network	CNN
8	الالتفاف	Convolution	—
9	التعلم بالنقل	Transfer Learning	—
10	زيادة البيانات	Data Augmentation	—
11	الدقة	Accuracy	—
12	الاستدعاء	Recall	—
13	الإحكام / الدقة	Precision	—
14	فيروس الورم الحليمي البشري	Human Papillomavirus	HPV
15	بقع بيضاء داخل الفم (الطلاوة)	Leukoplakia	—
16	بقع حمراء داخل الفم (الحمرة)	Erythroplakia	—
17	التعلم الآلي	Machine Learning	ML
18	التعلم العميق	Deep Learning	DL
19	واجهة برمجة التطبيقات	Application Programming Interface	API
20	التصنيف	Classification	—

الرقم	المصطلح بالعربية	المصطلح بالإنجليزية	الاختصار
21	التنبؤ	Prediction	—
22	العنقدة (التجميع)	Clustering	—
23	شبكة عصبية اصطناعية	Artificial Neural Network	ANN
24	هندسة الميزات	Feature Engineering	—
25	طبقة الإدخال	Input Layer	—
26	طبقة الإخراج	Output Layer	—
27	الطبقات المخفية	Hidden Layers	—
28	العقد	Nodes	—
29	آلة ناقلات الدعم	Support Vector Machine	SVM
30	معالجة البيانات	Data Processing	—
31	إطار البيانات	Data Frame	—
32	التدريب	Training	Train
33	الاختبار	Testing	Test
34	الميزات (السمات)	Features	—
35	مصفوفة الارتباك	Confusion Matrix	—
36	علم الأنسجة المرضي	Histopathology	—
37	إيجابي حقيقي	True Positive	TP
38	سلبي حقيقي	True Negative	TN
39	إيجابي كاذب	False Positive	FP
40	سلبي كاذب	False Negative	FN

الفصل الأول: المقدمة

1.1 تمهيد عن المشروع

تعريف سرطان الفم

سرطان الخلايا الحرفية الفموية (Oral Squamous Cell Carcinoma – OSCC) هو أحد أكثر أنواع السرطان شيوعاً في منطقة الرأس والعنق، ويُعتبر من الأمراض الخطيرة التي تهدد حياة المرضى إذا لم يتم اكتشافها ومعالجتها في مراحلها المبكرة.

يمثل تحدياً صحياً عالمياً يستدعي اهتماماً متزايداً في عام 2020، تجاوز عدد الحالات الجديدة المُشخصة بسرطان الفم ومناطق الرأس والعنق الأخرى 377,000 حالة حول العالم، مع أكثر من 177,000 وفاة مرتبطة بهذا المرض، مما يبرز الحاجة الملحة لتعزيز جهود الكشف المبكر والتدخل الفعال

إن **الكشف المبكر** يلعب دوراً حاسماً في زيادة معدلات البقاء على قيد الحياة وتحسين جودة حياة المرضى، حيث ترتفع فرص الشفاء بشكل ملحوظ عند تشخيص المرض في مراحله الأولية.

على الرغم من التطورات في التقنيات الطبية، لا يزال تشخيص سرطان الفم يعتمد بشكل كبير على الفحص البصري اليدوي والخزعات النسيجية، وهي طرق قد تكون ذاتية وتستغرق وقتاً طويلاً، مما قد يؤخر التشخيص والعلاج. في هذا السياق، برزت **تقنيات الذكاء الاصطناعي (AI)** كأداة واعدة لإحداث ثورة في المجال الطبي، خاصة في مهام التصوير والتشخيص. تستطيع هذه التقنيات تحليل كميات هائلة من البيانات الطبية، مثل الصور الشعاعية والفحوصات النسيجية، لتحديد الأنماط المعقدة التي قد تغفل من الفحص البشري.

يهدف هذا المشروع إلى استكشاف إمكانيات الذكاء الاصطناعي في تحسين دقة وسرعة الكشف عن سرطان الفم. قمنا بتطوير وتدريب نموذج تعلم عميق باستخدام بنية **AlexNet & InceptionV3**، وهي من البنية الشبكة العصبية التلافيفية (CNN) معروفة بقدرتها الفائقة على التعرف على الأنماط في الصور من خلال الاستفادة من هذه التقنية المتقدمة، نسعى لتقديم حل مساعد للأطباء يمكنه دعمهم في اتخاذ قرارات تشخيصية أكثر دقة وفي وقت أقل، وبالتالي المساهمة في إنقاذ الأرواح وتحسين نتائج العلاج لمرضى سرطان الفم.

1.2 المشكلة التي يحلها المشروع

يمثل سرطان الفم تحديًا صحيًا كبيرًا يتطلب اهتمامًا فوريًا وفعّالًا، وتكمن المشكلة الرئيسية التي يسعى هذا المشروع لحلّها في الصعوبات والتحديات المرتبطة بالكشف المبكر والدقيق عن هذا المرض على الرغم من أن الكشف المبكر هو العامل الأكثر تأثيرًا في تحسين فرص البقاء على قيد الحياة للمرضى، إلا أن العملية التشخيصية الحالية تواجه عدة قيود:

1. **الاعتماد على الفحص البصري الذاتي:** يعتمد التشخيص الأولي لسرطان الفم بشكل كبير على الفحص البصري الذي يجريه الأطباء المتخصصون هذه الطريقة قد تكون ذاتية وتتأثر بخبرة الفاحص ومدى وضوح الأعراض في المراحل المبكرة غالبًا ما تكون الآفات السرطانية في بدايتها غير واضحة وقد تتشابه مع حالات حميدة، مما يزيد من صعوبة التمييز ويؤدي إلى تأخير في التشخيص.

2. **استغراق الوقت في التشخيص:** بعد الفحص البصري، يتطلب التشخيص النهائي غالبًا إجراء خزعة نسيجية (Biopsy) وتحليلها تحت المجهر هذه العملية تستغرق وقتًا، وقد تمتد لعدة أيام أو حتى أسابيع، وهي فترة حرجية يمكن أن تسمح للمرض بالتقدم، خاصةً في الحالات سريعة التطور هذا التأخير يمكن أن يؤثر سلبًا على خطة العلاج ونتائجه.

3. **تأخير الإحالة والعلاج:** نتيجة للقيود المذكورة أعلاه، قد لا يتم اكتشاف سرطان الفم إلا في مراحله المتقدمة عندما يتم التشخيص متأخرًا، يصبح العلاج أكثر تعقيدًا وتدخلاً (مثل الجراحة الواسعة، والعلاج الإشعاعي، والعلاج الكيميائي)، مما يزيد من الآثار الجانبية ويقلل من معدلات البقاء على قيد الحياة وجودة حياة المريض بعد العلاج.

4. **نقص المتخصصين في بعض المناطق:** قد لا تتوفر الخبرة المتخصصة في تشخيص سرطان الفم بسهولة في جميع المناطق، خاصة في المجتمعات النائية أو المناطق ذات الموارد المحدودة، مما يحد من فرص الكشف المبكر.

يسعى هذا المشروع إلى التخفيف من هذه التحديات من خلال تطوير نظام تشخيص مساعد يعتمد على الذكاء الاصطناعي باستخدام نموذج AlexNet & InceptionV3، نهدف إلى توفير نموذج يمكنه تحليل الصور الطبية بكفاءة عالية، مما يساعد على:

✚ تحسين الدقة في تحديد الآفات المشتبه بها.

✚ تسريع عملية الفرز والكشف الأولي.

✚ تقليل الاعتماد على التقييم البشري الذاتي في المراحل الأولية.

بذلك، يساهم المشروع في تمكين الأطباء من اتخاذ قرارات تشخيصية أسرع وأكثر استنارة، مما يقلل من التأخير في بدء العلاج ويؤدي في النهاية إلى تحسين كبير في نتائج المرضى المصابين بسرطان الفم.

على الرغم من توفر تقنيات تصوير متعددة وأساليب تشخيصية متقدمة، إلا أن التشخيص يعتمد بشكل كبير على الخبرة الطبية والتحليل البشري، الذي قد يكون معرضاً للخطأ أو التأخير بسبب عدة عوامل منها ضغط العمل أو قلة الخبرة المتخصصة. هناك فجوة واضحة في توفير أداة ذكية وفعالة تساعد في تحليل الصور الطبية بسرعة ودقة عالية، لتقديم دعم فعلي للأطباء في اتخاذ القرار التشخيصي. يعالج مشروعنا هذه الفجوة من خلال تطوير أداة تعتمد على تقنيات الذكاء الاصطناعي لتحليل صور OSCC ، مما يسرع عملية التشخيص ويقلل من الأخطاء المحتملة.

1.3 أهداف المشروع

الهدف الأساسي لهذا المشروع هو تسخير قوة الذكاء الاصطناعي، وتحديدًا تقنيات التعلم العميق، لتعزيز دقة وكفاءة عملية الكشف عن سرطان الفم

نسعى لتحقيق هذا الهدف من خلال تطوير نموذج التعلم العميق قادر على تحليل الصور الطبية المرتبطة بسرطان الفم، وذلك لتحقيق الأهداف التفصيلية التالية:

(1) **تحسين دقة التشخيص المبكر:** يتمثل الهدف الأسمى في بناء نظام يتمتع بقدرة عالية على التمييز بين الأنسجة السليمة والآفات السرطانية أو ما قبل السرطانية في الصور هذا سيؤدي إلى زيادة نسبة الحالات التي يتم اكتشافها في مراحلها المبكرة، مما يعظم فرص الشفاء الكامل للمرضى.

(2) **تسريع عملية الفرز والتقييم الأولي:** يهدف المشروع إلى توفير أداة يمكنها مساعدة الأطباء وطواقم الرعاية الصحية في تحديد الحالات المشتبه بها بسرعة أكبر هذا سيسهم في تقليل الوقت المستغرق في التشخيص الأولي، مما يسمح ببدء الإجراءات التشخيصية التأكيدية (مثل الخزعة) والعلاج في وقت مبكر.

(3) **تقليل الأخطاء البشرية والتباين في التشخيص:** من خلال توفير تقييم موضوعي ومبني على البيانات للصور، يهدف المشروع إلى تقليل الاعتماد على التقييم الذاتي للفاحصين والذي قد يختلف من طبيب لآخر هذا سيؤدي إلى تشخيص أكثر اتساقًا وموثوقية عبر مختلف الحالات والمراكز الطبية.

(4) **دعم الأطباء كأداة مساعدة (Decision Support Tool):** لا يهدف المشروع إلى استبدال الخبرة البشرية، بل يهدف إلى الدعم الأطباء في اتخاذ قراراتهم و سيوفر النموذج إشارات تنبيهية للحالات المشتبه بها، مما يمكن الأطباء من التركيز على المناطق الأكثر أهمية وإجراء فحص معمق لها.

(5) **استغلال إمكانيات نموذج InceptionV3:** يهدف المشروع بشكل خاص إلى تقييم فعالية وقدرة بنية الشبكة العصبية التلافيفية InceptionV3 في معالجة وتحليل صور سرطان الفم، وإظهار كيف يمكن لبنية متقدمة كهذه أن تساهم في تحقيق نتائج تشخيصية قوية.

في جوهره، يسعى هذا المشروع إلى تقديم مساهمة عملية في مجال الرعاية الصحية، من خلال الاستفادة من التطورات في الذكاء الاصطناعي لإنقاذ الأرواح وتحسين جودة حياة مرضى سرطان الفم.

1.4.1 بنية تقرير المشروع

يتضمن هذا التقرير الأقسام التالية:

1. الفصل الأول :المقدمة.
2. الفصل الثاني الدراسة النظرية
3. الفصل الثالث:الدراسات المرجعية.
4. الفصل الرابع :منهجية العمل.
5. الفصل الخامس :معايير التقييم والنتائج.
6. الفصل السادس.:الخلاصة والتوصيات والاعمال المستقبلية

الفصل الثاني : الدراسة النظرية

2.1 مقدمة

يشهد مجال الذكاء الاصطناعي تطورًا متسارعًا في التطبيقات الطبية، وخاصة في تحليل الصور المجهرية وتشخيص الأمراض السرطانية. وتُعد تقنيات التعلم العميق (Deep Learning) من أكثر الأساليب فعالية في استخراج الأنماط والميزات المعقدة من الصور الطبية، مما يساهم في دعم التشخيص المبكر للأمراض وزيادة دقة القرارات الطبية.

في هذا المشروع تم الاعتماد على عدة نماذج حديثة تشمل الشبكات العصبية التلافيفية (CNN) ، والمحولات البصرية (Vision Transformers) ، وتقنيات دمج البيانات متعددة الوسائط (Multimodal Learning) ، بالإضافة إلى نماذج كشف الأجسام (Object Detection) بهدف بناء نظام ذكي متكامل للكشف عن سرطان الفم.

2.2 سرطان الفم (Oral Squamous Cell Carcinoma – OSCC)

2.2.1 تعريف المرض

سرطان الخلايا الحرشفية الفموية (OSCC) هو أكثر أنواع سرطانات الفم انتشارًا، وينشأ من الخلايا الطلائية المبطنة للفم واللسان واللثة.

2.2.2 عوامل الخطر

- التدخين .
- الكحول .
- مضغ التبغ .
- العوامل الوراثية .
- العمر .
- الالتهابات المزمنة .

وهذه العوامل استُخدمت ضمن البيانات السريرية للنموذج المدمج .

الشكل التالي يوضح قرحة السرطان داخل الفم:



الشكل 1.1 : سرطان الفم — قرحة حمراء

2.3 الذكاء الاصطناعي في المجال الطبي

المفاهيم الأساسية للذكاء الاصطناعي

- **الذكاء الاصطناعي (Artificial Intelligence - AI)** المظلة العامة التي تشمل بناء أنظمة وبرمجيات ذكية قادرة على محاكاة القدرات الذهنية البشرية، مثل التفكير، والتعلم، وحل المشكلات، لاتخاذ قرارات مستقلة أو شبه مستقلة.
- **تعلم الآلة (Machine Learning - ML)** فرع أساسي من الذكاء الاصطناعي يعتمد على تدريب الخوارزميات على كميات ضخمة من البيانات بدلاً من برمجة القواعد يدوياً. تتيح هذه التقنية للنظام الاكتشاف الذاتي للأنماط والتنبؤ بالمخرجات المستقبلية بناءً على البيانات التاريخية.
- **التعلم العميق (Deep Learning - DL)** ترقية متقدمة لتعلم الآلة تعتمد على الشبكات العصبية الاصطناعية (**Artificial Neural Networks**) ذات الطبقات المتعددة. تمتاز بقدرتها العالية على معالجة البيانات غير المهيكلة (مثل الصور الطبية والمقاطع الصوتية) واستخراج الميزات المعقدة منها تلقائياً دون تدخل بشري.

- الرؤية الحاسوبية: (Computer Vision – CV) حقل متخصص يهدف إلى تمكين الآلات من "رؤية" البيانات Visual وتحليلها. تعتمد بشكل وثيق على التعلم العميق لمعالجة الصور وفيديوهات الفحص الطبي، واستخراج التفاصيل الدقيقة التي قد تصعب على العين المجردة.

دور الذكاء الاصطناعي في المجال الطبي

1. تحليل الصور الطبية

تُستخدم تقنيات الرؤية الحاسوبية والتعلم العميق لقراءة الأشعة (X-Ray)، والتصوير بالرنين المغناطيسي (MRI)، والأشعة المقطعية (CT Scans). تقوم الخوارزميات بتحديد الأورام، الكسور، والآفات النسيجية بدقة متناهية، وتصنيف الأنسجة إلى سليمة أو خبيثة خلال ثوانٍ.

2. دعم الأطباء (أنظمة اتخاذ القرار)

يعمل الذكاء الاصطناعي كمساعد افتراضي للأنظمة الطبية؛ إذ يربط بين التاريخ المرضي للمريض، والتحاليل المخبرية، والأبحاث الطبية الحديثة لتقديم توصيات علاجية مخصصة، وتقليل العبء الإداري، والتنبؤ بالتدخلات الدوائية الضارة.

3. التشخيص المبكر

يكشف الذكاء الاصطناعي عن التغيرات البيولوجية والأنماط الدقيقة في بيانات المريض قبل ظهور الأعراض السريرية الواضحة. يظهر هذا بوضوح في الكشف المبكر عن أورام الثدي، واعتلال الشبكية السكري، ومرض ألزهايمر، مما يزيد فرص الشفاء بدرجة كبيرة.

2.4 التعلم العميق (Deep Learning)

يتكون التعلم العميق من طبقات عصبية متعددة تستطيع استخراج الميزات تلقائيًا من البيانات.

أنواع النماذج المستخدمة:

- CNN.

Transformers. •

Multimodal Networks. •

2.5 الشبكات العصبية التلافيفية (CNN)

1. طبقة التلافيف (Convolution Layer)

- **الوظيفة:** هي القلب النابض لشبكة CNN والمسؤولة عن استخراج الميزات (Features) من الصور.
- **كيفية العمل:** تمرر مرشحات (Filters/Kernels) صغيرة الحجم على الصورة المدخلة لتطبيق عمليات ضرب مصفوفي. تُستخرج الميزات البسيطة في الطبقات الأولى (مثل الحواف والزوايا)، وتندمج لتشكيل ميزات أكثر تعقيداً في الطبقات الأعمق (مثل الأشكال والوجوه).

2. طبقة التجميع (Pooling Layer)

- **الوظيفة:** تقليل الأبعاد الفضائية (العرض والارتفاع) لخريطة الميزات (Feature Map)، مما يقلل الحسابات والذاكرة المطلوبة ويمنع التفرطح (Overfitting).
- **كيفية العمل:** تأخذ منطقة صغيرة من خريطة الميزات وتستخلص منها قيمة واحدة، وأشهر أنواعها:
 - **Max Pooling:** تُحدد القيمة العظمى في المنطقة (الأكثر استخداماً لأنها تحتفظ بالميزات الأكثر بروزاً).
 - **Average Pooling:** تحسب المتوسط الحسابي للقيم.

3. دواء التنشيط (Activation Functions)

- **الوظيفة:** إدخال عدم خطية (Non-linearity) إلى الشبكة العصبية، مما يتيح لها تعلم أنماط وعلاقات معقدة جداً لا يمكن للدوال الخطية تمثيلها.
- **أبرز أمثلتها:**
 - **ReLU (Rectified Linear Unit):** تحول القيم السالبة إلى 0 وتحتفظ بالقيم الموجبة. كما هي $f(x) = \max(0, x)$ ، وهي الأكثر شيوعاً في طبقات التلافيف لسرعتها وكفاءتها.

○ **Sigmoid / Softmax:** تُستخدم عادة في الطبقة الأخيرة لتحويل المخرجات إلى احتمالات (Probabilities) تصنيفية.

4. الطبقة المترابطة بالكامل (Fully Connected Layer – FC)

- **الوظيفة:** تجميع كافة الميزات المستخرجة من الطبقات السابقة لاتخاذ القرار النهائي وتصنيف الصورة.
- **كيفية العمل:** يتم أولاً تحويل الميزات ثنائية/ثلاثية الأبعاد إلى متجه أحادي البعد (Flattening) ، ثم تُوصّل كل خلية عصبية في هذه الطبقة بكافة الخلايا في الطبقة السابقة، لتخرج النسب والاحتمالات لكل فئة (Class).

5. إسقاط الخلايا / الإغفال (Dropout)

- **الوظيفة:** تقنية تنظيمية (Regularization) تُستخدم لمنع مشكلة الإفراط في التعلم (Overfitting) ولضمان تعميم النموذج على بيانات جديدة.
- **كيفية العمل:** أثناء عملية التدريب، يتم تعطيل (إسقاط) نسبة مئوية عشوائية من الخلايا العصبية (مثلاً 20% أو 50%) في كل دورة تدريبية (Epoch) هذا يجبر الشبكة على عدم الاعتماد على خلايا محددة و يتيح للنموذج تعلم ميزات أكثر متانة.

2.6 نموذج AlexNet

AlexNet هو نموذج CNN عميق تم تطويره عام 2012 ويحتوي على طبقات التفاف وتجميع وطبقات كاملة الاتصال.

مميزات النموذج:

- استخراج الميزات .
- معالجة الصور الطبية .
- استخدام ReLU .
- استخدام Dropout .

2.7 نموذج InceptionV3

نموذج يعتمد على:

- Transfer Learning.
- Inception Modules.
- GlobalAveragePooling.
- Dense Layers.

وقد استُخدم لاستخراج الميزات من صور سرطان الفم.

2.8 التعلم بالنقل (Transfer Learning)

- النماذج المدربة مسبقاً: (Pre-trained Models)

شبكات عصبية تم تدريبها سابقاً على مجموعات بيانات ضخمة جداً لحل مشكلة معينة (مثل تصنيف الصور)، وتكون جاهزة للاستخدام أو للتعديل دون الحاجة لتدريبها من الصفر.

- ImageNet:

قاعدة بيانات عالمية ضخمة تحتوي على أكثر من 14 مليون صورة مصنفة إلى آلاف الفئات، وتُعد المعيار الأساسي لتدريب واختبار أداء نماذج الرؤية الحاسوبية والتعلم العميق.

- إعادة استخدام الأوزان: (Transfer Learning / Weight Re-use)

تقنية أخذ الأوزان (Weights) التي تعلمها النموذج المسبق من بيانات ضخمة (مثل ImageNet ، وتطبيقها على مهمة جديدة أو مجال مختلف (مثل الصور الطبية). هذا يوفر الوقت والموارد الحسابية ويحقق دقة عالية حتى مع قلة البيانات الجديدة.

وهذا ينطبق على:

- InceptionV3

• ViT

• MobileNet

2.9 Vision Transformer (ViT)

Vision Transformer هو نموذج يعتمد على آلية الانتباه (Self-Attention) بدلاً من الالتفافات.

آلية العمل:

1. تقسيم الصورة إلى Patches.

2. تحويلها إلى Embeddings.

3. إدخالها إلى Transformer Encoder.

4. استخراج الميزات .

5. التصنيف النهائي .

النموذج المستخدم:

ViT-Base-Patch16-224.

2.10 البيانات السريرية (Clinical Data)

الميزات المستخدمة:

• العمر .

• الجنس .

- التدخين .
- الكحول .
- مضغ التبغ .
- التاريخ العائلي.

2.11 التعلم متعدد الوسائط (Multimodal Learning)

- هذا أهم جزء جديد بالمشروع.
- يعتمد على دمج:
- الصور المجهرية .
- البيانات السريرية .
- ثم دمج الميزات باستخدام Concatenate Layer قبل التصنيف النهائي

2.12 نموذج MobileNet

تم استخدام MobileNet كنموذج خفيف الوزن داخل التطبيق النهائي للمقارنة السريعة والتشغيل على الأجهزة ذات الموارد المحدودة .

Depthwise Convolution (التلافيف العميق) :

يُطبق مرشحاً (Filter) واحداً على كل قناة (Channel) في الصورة بشكل منفصل، بدلاً من التطبيق على جميع القنوات معاً. هذا يقلل الحسابات بنسبة كبيرة جداً.

Pointwise Convolution (التلافيف النقطي):

يستخدم مرشحات بحجم 1×1 لدمج مخرجات القنوات المختلفة الناتجة عن الخطوة السابقة، لإنشاء ميزات جديدة وتغيير عدد القنوات حسب الحاجة.

السرعة:

، ينخفض عدد العمليات (Depthwise + Pointwise) بفضل تقسيم التلافيف التقليدي إلى خطوتين الحسابية بشكل هائل، مما يجعل النموذج سريعاً جداً في المعالجة واتخاذ القرارات لحظياً

Low Parameters Count (قلة عدد المعاملات):

يحتاج النموذج إلى عدد أقل بكثير من الأوزان والمتغيرات مقارنة بالشبكات التقليدية مثل (VGG أو ResNet) مما يقلل حجمه ويرشد استهلاك الذاكرة (RAM) ، فيجعله مثالياً للتشغيل على الأجهزة المحدودة مثل الهواتف المحمولة والأنظمة المدمجة

2.13 نموذج YOLOv8 :

تم استخدام YOLOv8 للكشف عن الخلايا أو المناطق المشبوهة داخل الصور المجهرية .

• كشف الكائنات: (Object Detection)

مهمة في الرؤية الحاسوبية لا تقتصر فقط على التعرف على نوع العناصر الموجودة في الصورة (تصنيف)، بل تتعدى ذلك لتحديد مواقعها بالضبط داخل الصورة.

• صناديق الإحاطة: (Bounding Boxes)

مستطيلات إحداثيات وهمية يرسمها النموذج حول الكائن المكتشف لتحديد مكانه بوضوح، وتُعرف عادةً بـ 4 إحداثيات: المركز أو الزاوية (x, y) بالإضافة إلى العرض والارتفاع (w, h) .

• درجة الثقة: (Confidence Score)

قيمة احتمالية (تتراوح عادةً بين 0% و 100% أو 0 و 1) تعبر عن مدى تأكد النموذج من شقين: وجود كائن داخل المربع بالفعل، وصحة التصنيف المنسوب لهذا الكائن (مثلاً: ثقة بنسبة 98% أن الكائن المكتشف هو أورام أو كسر).

2.14 تفسير النماذج (Explainable AI)

تم استخدام:

• Heatmaps.

• Grad-CAM.

لفهم المناطق التي اعتمد عليها النموذج أثناء اتخاذ القرار

• Data Augmentation.

• Early Stopping.

• ReduceLROnPlateau.

• Model Checkpoint.

• Class Weights.

• Dropout

2.16 مقاييس التقييم

1. مصفوفة الارتباك (Confusion Matrix)

جدول إحصائي يوضح أداء النموذج من خلال المقارنة بين التوقعات والحقيقة عبر 4 قيم أساسية:


• **True Positive (TP):** توقع إيجابي وهو فعلاً إيجابي.

• **True Negative (TN):** توقع سلبي وهو فعلاً سلبي.

• **False Positive (FP):** توقع إيجابي ولكنه في الحقيقة سلبي (إنذار خاطئ).

• **False Negative (FN):** توقع سلبي ولكنه في الحقيقة إيجابي (خطأ خطير).

الشكل التالي يوضح مصفوفة الارتباك:



الشكل 1.2 مصفوفة الارتباك

2. الدقة العامة (Accuracy)

- المفهوم: نسبة التوقعات الصحيحة بالكامل (إيجابية وسلبية) من إجمالي عدد التوقعات.

- الاستخدام: ممتازة عندما تكون البيانات متوازنة بين الفئات.

3. الدقة التنبؤية (Precision)

- المفهوم: من بين جميع الحالات التي توقع النموذج أنها إيجابية، كم حالة منها كانت إيجابية فعلاً؟
- الاستخدام: مهمة جداً عندما تكون تكلفة الإنذار الخاطئ (False Positive) مرتفعة) مثل تصنيف البريد كـ Spam).

4. الحساسية / الاستدعاء (Recall)

- المفهوم: من بين جميع الحالات الإيجابية الحقيقية الموجودة بالبيانات، كم حالة نجح النموذج في اكتشافها؟
- الاستخدام: حاسمة جداً في المجال الطبي (مثل اكتشاف الأورام)، حيث يُعد تقويت حالة إيجابية واحدة (False Negative) أمراً خطيراً.

5. قياس (F1-Score) F1

- المفهوم: المتوسط الهندسي لـ Precision والـ Recall.
- الاستخدام: يُعطي مقياساً واحداً متوازناً، وهو أفضل معيار للتقييم عندما تكون البيانات غير متوازنة (Imbalanced Data).

الفصل الثالث : الدراسات المرجعية

3.1 مقدمة

شهدت السنوات الأخيرة تطورًا متسارعًا في استخدام تقنيات الذكاء الاصطناعي والتعلم العميق في مجال تشخيص الأمراض، وخاصة في تحليل الصور الطبية والصور النسيجية المرضية. ويُعد سرطان الخلايا الحشرية الفموية (Oral Squamous Cell Carcinoma – OSCC) من المجالات التي استفادت من هذه التطورات، نتيجة قدرة نماذج التعلم العميق على استخراج الأنماط والخصائص البصرية المعقدة من الصور.

أظهرت الدراسات السابقة إمكانية استخدام خوارزميات التعلم الآلي التقليدية مثل SVM و KNN، ثم تطورت المنهجيات نحو الشبكات العصبية التلافيفية CNN ونماذج Transfer Learning مثل AlexNet و EfficientNet، وصولًا إلى نماذج Transformer و Vision Transformer والنماذج متعددة الوسائط التي تجمع بين الصور والبيانات السريرية.

كما اتجهت الدراسات الحديثة إلى استخدام تقنيات الكشف والتقسيم مثل YOLO، بالإضافة إلى تقنيات Explainable AI بهدف جعل قرارات النماذج أكثر قابلية للتفسير.

والآن سوف نعرض بعض الدراسات التي تطرقنا إليها :

3.2 الدراسة الأولى: تحليل الصور النسيجية المرضية لتصنيف سرطان الفم باستخدام SVM

تناولت دراسة **Bakare and Kumarasamy (2021)** استخدام تقنيات التعلم الآلي لتصنيف سرطان الفم اعتمادًا على الصور النسيجية المرضية.

اعتمدت الدراسة على مراحل شملت المعالجة المسبقة للصور، واستخراج الميزات، ثم التصنيف باستخدام خوارزميات **Support Vector Machine (SVM)** و **K-Nearest Neighbour (KNN)**.

حققت خوارزمية SVM دقة بلغت حوالي 98%، بينما حققت KNN دقة بلغت حوالي 83%، مما أظهر تفوق SVM في التجربة .

علاقتها بالمشروع

تمثل هذه الدراسة المرحلة التقليدية من تحليل الصور الطبية، بينما يعتمد مشروعنا على التعلم العميق الذي يستطيع تعلم الميزات مباشرة من الصور بدل الاعتماد الكامل على استخراج الميزات يدويًا.

3.3 الدراسة الثانية: مراجعة استخدام التعلم الآلي في تحليل صور سرطان الفم

قدم **Panigrahi and Swarnkar (2020)** مراجعة حول استخدام تقنيات Machine Learning و Deep Learning في تحليل الصور النسيجية لسرطان الفم.

استعرضت الدراسة مجموعة من الخوارزميات، منها SVM و KNN والشبكات العصبية التلافيفية، وأوضحت أن استخدام التعلم العميق أصبح اتجاهًا مهمًا في تحليل الصور النسيجية بسبب قدرته على تعلم الخصائص البصرية المعقدة .

علاقتها بالمشروع

تدعم هذه الدراسة الانتقال من أساليب Machine Learning التقليدية إلى Deep Learning ، وهو الاتجاه الذي اتبعه مشروعنا.

3.4 الدراسة الثالثة: استخدام AlexNet و Transfer Learning

في دراسة **Rahman et al. (2022)** بعنوان:

Histopathologic Oral Cancer Prediction Using Oral Squamous Cell Carcinoma Biopsy Empowered with Transfer Learning

تم استخدام **AlexNet** ضمن منهجية Transfer Learning لتحليل صور خزعات OSCC.

استخدمت الدراسة صورًا نسيجية مرضية لسرطان الفم، وحقت دقة بلغت **97.66%** في التدريب و**90.06%** في الاختبار .

علاقتها بالمشروع

هذه الدراسة مرتبطة بشكل مباشر بمشروعنا، لأننا استخدمنا **AlexNet** أيضًا لتصنيف صور OSCC. لكن مشروعنا يختلف عنها في أنه لا يعتمد على AlexNet فقط، وإنما يقارن عدة معماريات ويضيف ViT و Multimodal Learning و MobileNet و YOLOv8.

3.5 الدراسة الرابعة: نموذج Deep Learning للكشف عن OSCC

قدمت دراسة **Histopathology–Based Diagnosis of Oral Squamous Cell Carcinoma Using Deep Learning** نموذجًا مخصصًا للكشف عن OSCC من الصور النسيجية.

استخدمت الدراسة **2025 صورة**، منها 1925 صورة للتدريب و 100 صورة للاختبار .

حقق النموذج:

- Sensitivity = **98%**
- Specificity = **92%**
- PPV = **92.4%**
- NPV = **97.8%**
- F1–Score = **95.1%**

كما درست الدراسة إمكانية مساعدة النموذج للأطباء في عملية التشخيص .

علاقتها بالمشروع

تدعم هذه الدراسة فكرة استخدام Deep Learning كأداة مساعدة للطبيب بدلاً من الاعتماد على الفحص اليدوي فقط.

3.6 الدراسة الخامسة EfficientNetB3: للكشف عن OSCC

قدمت دراسة (Albalawi et al. (2024) نموذجًا يعتمد على EfficientNetB3 لتصنيف الصور النسيجية إلى نسيج طبيعي و OSCC.

استخدمت الدراسة مجموعة بيانات تحتوي على 1224 صورة من 230 مريضاً، مع صور بمستويات تكبير مختلفة.

تم استخدام Data Augmentation و Regularization و Optimization أثناء التدريب.

حقق النموذج دقة بلغت حوالي 99% على مجموعة الاختبار .

علاقتها بالمشروع

هذه الدراسة مهمة جدًا بالنسبة لمشروعنا لأن مجموعة البيانات التي بدأ منها مشروعنا مرتبطة بهذه المجموعة البحثية؛ كما أن الدراسة أثبتت قدرة نماذج Deep Learning الحديثة على التمييز بين Normal و OSCC.

3.7 الدراسة السادسة: المراجعة المنهجية للتعلم العميق في سرطان الفم

قدم (Warin and Suebnukarn (2024) مراجعة منهجية واسعة لدراسات Deep Learning في تشخيص سرطان الفم والتنبؤ به.

شملت المراجعة 54 دراسة، منها 51 دراسة تشخيصية و 3 دراسات للتنبؤ.

وجدت المراجعة أن دقة نماذج التصنيف في الدراسات المختلفة تراوحت بين 85% و 100%، كما تراوحت نتائج Object Detection من حيث F1-Score بين 79.31% و 89%، بينما تراوحت نتائج Segmentation من حيث Dice بين 76% و 96.3%.

علاقتها بالمشروع

توضح هذه الدراسة أن مجال AI في سرطان الفم أصبح واسعاً، وأن استخدام التصنيف والكشف والتقسيم يمثل اتجاهاً مهماً في الأبحاث الحالية.

3.8 الدراسة السابعة: المراجعة والتحليل التجميعي لـ OSCC

قدم Pirayesh et al. (2024) مراجعة منهجية وتحليلاً تجميعياً لدراسات Deep Learning المستخدمة في تحليل الصور النسيجية لـ OSCC.

بعد فحص 1267 دراسة، تم تضمين 17 دراسة في التحليل النهائي.

وجدت الدراسة أن دراسات التصنيف أظهرت في بعض الحالات:

• Accuracy = 0.99

• Sensitivity = 0.99

• Specificity = 1.00

• F1 = 0.98

• AUC = 0.99

كما بلغ التقدير المجمع للحساسية 0.98 وللنوعية 0.93.

علاقتها بالمشروع

تؤكد هذه النتائج الإمكانيات العالية للتعلم العميق في تحليل الصور النسيجية، لكنها تؤكد أيضاً أهمية تقييم خطر الانحياز والتحقق الخارجي قبل الانتقال إلى الاستخدام السريري

3.9 الدراسة الثامنة Vision Transformer: قابل للتفسير لسرطان الفم

وهذه من أهم الدراسات الجديدة بالنسبة لمشروعك.

في عام 2026 قدمت دراسة بعنوان:

Explainable Vision Transformer Framework for Multi-Class Classification and Prognostic Interpretation of Oral Cancer in Histopathology Images

استخدمت الدراسة نموذج **Explainable Vision Transformer (MMX-ViT)** يجمع بين استخراج الميزات باستخدام CNN وآلية Attention الخاصة بالـ Transformer.

تمت مقارنة النموذج مع ثمانية نماذج حديثة، وحقق النموذج:

• Accuracy = **98.45%**

• AUC = **0.99**

• Explainability Consistency Index = **94%**

كما استخدمت الدراسة **Grad-CAM++** و **SHAP** و **Transformer Attention Rollout** للتفسير قرارات النموذج .

علاقتها بالمشروع

هذه الدراسة مرتبطة مباشرة بالجزء الجديد في مشروعنا الخاص بـ:

Vision Transformer + Explainable AI / Heatmap

وهي تعطي دعماً علمياً قوياً لإضافة ViT والتفسير البصري إلى المشروع.

3.10 الدراسة التاسعة Hybrid Transformer: للكشف عن OSCC

في دراسة منشورة عام 2026 بعنوان:

Attention-aided Hybrid Transformer Network for Oral Squamous Cell Carcinoma Classification Using Histopathology Images

تم اقتراح نموذج هجين يجمع بين:

• ResNet50.

- Vision Transformer.

- Convolutional Block Attention Module (CBAM).

استخدمت الدراسة **5192 صورة نسيجية مرضية**، وحقق النموذج المقترح Accuracy بلغت **98.97%**.

وأظهرت النتائج أن دمج الميزات المحلية التي تستخرجها CNN مع الميزات العالمية التي يتعلمها Transformer يمكن أن يحسن عملية التصنيف .

علاقتها بالمشروع

تدعم هذه الدراسة الاتجاه الذي اتبعناه في استخدام ViT إلى جانب النماذج التقليدية، وتوضح أهمية الجمع بين المعلومات المحلية والعالمية في الصور النسيجية.

3.11 الدراسة العاشرة Multimodal Deep Learning :لسرطان الفم

وهذه أيضًا مهمة جدًا لمشروعك.

في دراسة بعنوان:

A Multimodal Deep Learning Pipeline for Enhanced Detection and Classification of Oral Cancer

تم دمج:

- Histopathological Images.

- Clinical Metadata.

وشملت البيانات معلومات سريرية مثل:

- العمر .

- الجنس .

- التدخين .
- الكحول .
- خصائص الآفة .
- التشخيص النهائي .

حققت المنهجية:

Accuracy = 0.97 •

Precision = 0.97 •

Recall = 0.98 •

F1-Score = 0.97. •

وتوضح الدراسة أن دمج المعلومات البصرية مع البيانات السريرية يمكن أن يوفر معلومات إضافية لا يمكن الحصول عليها من الصور وحدها .

علاقتها بالمشروع

هذه الدراسة هي الأقرب إلى فكرة Multimodal ViT الموجودة في مشروعنا، لأننا أيضًا ندمج الصورة مع البيانات السريرية.

3.12 الدراسة الحادية عشرة Multimodal AI: للتشخيص المبكر

في دراسة حديثة عام 2025 تم تطوير نظام ذكاء اصطناعي متعدد الوسائط لتصنيف آفات الفم إلى:

- Malignant.
- Potentially Malignant.
- Benign.
- Healthy.

تم استخدام الصور السريرية مع البيانات السريرية، وتمت مقارنة النماذج الأحادية مع نموذج Multimodal. حقق النموذج متعدد الوسائط:

• Accuracy = 92.17%

• Precision = 92.68%

• Recall = 92.69%

• F1 = 92.62%

• ROC-AUC = 99.01%

وكان أدائه أفضل من النماذج التي اعتمدت على مصدر واحد للبيانات . علاقتها بالمشروع

تدعم هذه الدراسة بشكل مباشر فكرة دمج أكثر من مصدر للمعلومات بدل الاعتماد على الصورة فقط.

3.13 الدراسة الثانية عشرة YOLOv8: للكشف عن سرطان الفم

وهذه الدراسة حديثة جدًا ومهمة لجزء YOLOv8 في مشروعنا.

في دراسة منشورة في 2026 بعنوان:

YOLOv8 Powered Deep Learning Framework for Detection and Classification of Oral Potentially Malignant Disorders and Oral Cancer Using Intraoral Images

تم استخدام YOLOv8 للكشف والتصنيف باستخدام صور سريرية داخل الفم.

استخدمت الدراسة 583 صورة أصلية، وتم توسيعها باستخدام Data Augmentation إلى 3285 صورة.

حقق نموذج: YOLOv8

• Accuracy = 98.83%

• Precision = 96.76%

• Recall = 98.24%.

علاقتها بالمشروع

تدعم هذه الدراسة استخدام YOLOv8 كجزء من النظام للكشف البصري، مع ملاحظة أن بياناتها صور سريرية داخل الفم وليست صور Histopathology ؛ لذلك لا ينبغي مقارنتها مباشرة بنتائج تصنيف صورنا النسيجية.

3.14 الدراسة الثالثة عشرة: مقارنة خمسة نماذج CNN

في دراسة حديثة جدًا عام 2026 بعنوان:

Deep Learning–Based Automated Detection of Oral Squamous Cell Carcinoma in Histopathological Images: A Comparative Study of Five CNN Architectures

تمت مقارنة خمسة نماذج:

• VGG16.

• ResNet50.

• InceptionV3.

• EfficientNetV2S.

• ConvNeXt–Tiny.

واستخدم الباحثون نفس ظروف التدريب والـ ImageNet pretrained weights للتحقيق مقارنة أكثر عدالة بين النماذج، مع تقييم Accuracy و Precision و Recall و Specificity و F1 و ROC–AUC.

علاقتها بالمشروع

هذه الدراسة مهمة لأنها تدعم فكرة مقارنة أكثر من Architecture بدل الاعتماد على نموذج واحد، وهو نفس الاتجاه الذي اتبعناه في مشروعنا.

3.15 الدراسة الرابعة عشرة: مشكلة التعميم واختلاف صبغة الصور

من الدراسات الحديثة المهمة دراسة:

A Histopathology Image–Based Computer–Aided Classification Study for Oral Squamous Cell Carcinoma

ركزت الدراسة على مشكلة اختلاف الصبغات والألوان في الصور النسيجية، والتي يمكن أن تجعل النموذج يتعلم اختلافات اللون بدلاً من تعلم الخصائص المرضية الفعلية.

استخدمت الدراسة آلية لتقليل تأثير الصبغة و Multiple–Instance Aggregation، وحققت على مجموعتي اختبار:

• Accuracy = 87.35% و 79.34 %

• F1 = 91.27% و 86.86 %

• AUC = 98.04% و 90.74 %

كما تم إجراء External Validation على مجموعة مستقلة، وهو أمر مهم جدًا للتحقق من قدرة النموذج على التعميم .

علاقتها بالمشروع

توضح هذه الدراسة أحد أهم التحديات التي يجب أخذها بالحسبان مستقبلاً، وهو أن ارتفاع Accuracy على Dataset واحدة لا يعني بالضرورة أن النموذج سيحافظ على الأداء نفسه على بيانات من مصدر آخر.

3.16 جدول المقارنة بين الدراسات السابقة والمشروع المقترح

علاقتها بمشروعنا	أهم نتيجة	المهمة	التقنية / النموذج	البيانات	السنة	الدراسة
أساس ML التقليدي	SVM ≈ 98% KNN ≈ 83%	Classification	SVM, KNN	Histopathology	2021	Bakare & Kumarasamy

علاقتها بمشروعنا	أهم نتيجة	المهمة	التقنية / النموذج	البيانات	السنة	الدراسة
الأساس النظري	توضيح تطور DL و ML	Review	ML / CNN	Oral Histopathology	2020	Panigrahi & Swarnkar
AlexNet	Train 97.66% Test 90.06%	Classification	AlexNet + Transfer Learning	OSCC biopsy	2022	Rahman et al.
Deep Learning	Sensitivity 98% Specificity 92%	Classification	Custom DL	OSCC histopathology	2022	Histopathology-based DL
Dataset / Deep Learning	Accuracy 99%	Classification	EfficientNetB3	1224 histopathology images	2024	Albalawi et al.
مراجع شامل للمجال	Accuracy 85-100%	Systematic Review	DL	Multiple studies	2024	Warin & Suebnukarn
دعم منهجي	Pooled Sensitivity 98%	Classification/Segmentation	DL	OSCC histopathology	2024	Pirayesh et al.
ViT + Explainability	Accuracy 98.45%, AUC 0.99	Classification	Explainable ViT	Oral histopathology	2026	Mahanty et al.
Hybrid Transformer	Accuracy 98.97%	Classification	ResNet50 + ViT + CBAM	5192 histopathology images	2026	Jagathesh & Narayanan
Multimodal Learning	Accuracy 97%, Recall 98%	Classification	Multimodal DL	Histopathology + Clinical	2025	Multimodal Deep Learning Pipeline
Multimodal AI	Accuracy 92.17%	4-class Classification	Multimodal AI	Clinical images + Clinical data	2025	Multimodal AI System

علاقتها بمشروعنا	أهم نتيجة	المهمة	التقنية / النموذج	البيانات	السنة	الدراسة
YOLOv8	mAP50 98.83%, Recall 98.24%	Detection/Segmentation	YOLOv8	Intraoral images	2026	Bharti et al.
Model Comparison	مقارنة CNN5	Classification	VGG16, ResNet50, InceptionV3, EfficientNetV2S, ConvNeXt	Histopathology	2026	Balel et al.
Generalization	External validation	Classification	Stain correction + MIL	Histopathology	2026	Histopathology CAD Study
نظام متعدد النماذج والوسائط	AlexNet: Accuracy 91.52%, Recall 96.02%, F1 91.98%	Classification + Detection + Explainability	AlexNet, InceptionV3, ViT, Multimodal ViT, MobileNet, YOLOv8	+ 4946 صورة Clinical Data	2026	المشروع المقترح

الجدول 2.1: المقارنة بين الدراسات المرجعية

الفصل الرابع: منهجية العمل

4.1 مقدمة

يهدف هذا الفصل إلى توضيح المنهجية المتبعة في تطوير النظام المقترح للكشف عن سرطان الخلايا الحشوية الغمية (OSCC) ، بدءًا من تجهيز البيانات ومعالجتها، مرورًا بتدريب نماذج التعلم العميق المختلفة، وانتهاءً بتقييم النماذج ودمجها ضمن نظام تطبيقي متكامل.

تعتمد المنهجية المقترحة على تحليل الصور المجهرية للأنسجة الغمية، بالإضافة إلى الاستفادة من البيانات السريرية للمريض في النموذج متعدد الوسائط. كما تم استخدام أكثر من نموذج بهدف مقارنة أساليب مختلفة في تحليل الصور، تشمل الشبكات العصبية التلافيفية، ونماذج Vision Transformer ، والنماذج الخفيفة، بالإضافة إلى نموذج للكشف البصري عن المناطق المشبوهة.

4.2 بيئة العمل والأدوات المستخدمة

تم تنفيذ مراحل تطوير المشروع باستخدام مجموعة من الأدوات والمكتبات البرمجية المتخصصة في التعلم العميق ومعالجة الصور وبناء التطبيقات التفاعلية.

4.2.1 لغة Python

تم الاعتماد على لغة **Python** باعتبارها اللغة الأساسية لتنفيذ مراحل المشروع المختلفة، بدءًا من قراءة البيانات ومعالجة الصور، وصولًا إلى تدريب النماذج وتقييمها وبناء واجهة التطبيق.

4.2.2 Google Colab

تم استخدام **Google Colab** كبيئة لتنفيذ وتجربة الأكواد وتدريب نماذج التعلم العميق، والاستفادة من موارد الحوسبة المتاحة لتقليل الزمن اللازم لتدريب النماذج.

4.2.3 Keras و TensorFlow .

تم استخدام **Keras** و **TensorFlow** في بناء وتدريب نماذج التعلم العميق، بما في ذلك:

- AlexNet.

- InceptionV3.
- نماذج التصنيف الأخرى .
- النموذج متعدد الوسائط .

كما تم استخدامهما في عمليات:

- بناء الشبكات العصبية .
- تدريب النماذج .
- حفظ النماذج .
- تحميل النماذج .
- إجراء التنبؤات.

Keras Hub / Vision Transformer.4.2.4

تم استخدام أدوات Keras المرتبطة بنماذج Transformer للاستفادة من نموذج **Vision Transformer (ViT)** في معالجة الصور واستخراج الميزات البصرية.

ويُستخدم ViT في المشروع ضمن النموذج متعدد الوسائط، حيث يتم دمج الميزات المستخرجة من الصور مع البيانات السريرية.

. OpenCV 4.2.5

تم استخدام مكتبة **OpenCV** في معالجة الصور وتنفيذ بعض العمليات المتعلقة بالصور والخرائط الحرارية والتعامل مع مخرجات التحليل البصري

NumPy.4.2.6

تم استخدام **NumPy** للتعامل مع البيانات الرقمية والمصفوفات، وتحويل الصور والنتائج إلى تمثيلات مناسبة لإدخالها إلى النماذج.

Pandas 4.2.7

تم استخدام **Pandas** في التعامل مع البيانات الجدولية، وخاصة البيانات السريرية للمريض وعمليات إنشاء DataFrame وربط معلومات الصور بالبيانات الأخرى.

ويظهر في الكود استخدام ملف البيانات السريرية patients.csv وقراءته باستخدام Pandas.

Scikit-learn 4.2.8

تم استخدام مكتبة **Scikit-learn** في عدد من عمليات معالجة البيانات والتقييم، وخاصة حساب:

- Accuracy.
- Precision.
- Recall.
- F1-Score.
- Confusion Matrix.
- Classification Report.

ويظهر استخدام هذه المقاييس مباشرة في كود تقييم AlexNet و ViT

Matplotlib 4.2.9

تم استخدام مكتبة **Matplotlib** لرسم النتائج البيانية، ومنها:

- Training Accuracy.
- Validation Accuracy.
- Training Loss.
- Validation Loss.
- Precision.

- Recall.
- Confusion Matrix.

فعلى سبيل المثال، يقوم الكود الخاص بـ ViT برسم منحنيات Accuracy و Loss و Precision و Recall أثناء التدريب

YOLOv8 و Ultralytics.4.2.10

تم استخدام مكتبة **Ultralytics** لتدريب وتشغيل نموذج **YOLOv8**.

استخدم المشروع نموذج:

YOLOv8n

وتم تدريبه على بيانات الكشف الخاصة بالمشروع باستخدام حجم صورة **640×640** ولمدة تصل إلى **50 Epochs**.

ويستخدم YOLOv8 في النظام للكشف وتحديد العناصر أو المناطق المشبوهة داخل الصور

Roboflow.4.2.11

تم استخدام **Roboflow** للحصول على وتجهيز مجموعة بيانات الكشف الخاصة بـ YOLOv8، حيث تم تحميل إصدار البيانات بصيغة مناسبة للتدريب باستخدام YOLOv8

Streamlit 4.2.12

تم استخدام **Streamlit** لبناء واجهة المستخدم الخاصة بالنظام.

وتتيح الواجهة:

- رفع الصورة .
- إدخال البيانات السريرية .

- اختيار النموذج .
- تشغيل التشخيص .
- عرض احتمالية الإصابة .
- عرض نتائج MobileNet.
- عرض نتائج YOLOv8.
- عرض الخرائط الحرارية .

ويحتوي التطبيق فعليًا على خيارات للتحليل الشامل باستخدام **ViT + MobileNet + YOLOv8** بالإضافة إلى خيارات منفصلة للنموذج متعدد الوسائط و MobileNet و YOLOv8.

4.3 مخطط العمل العام للنظام

يمكن تقسيم مراحل العمل إلى المراحل التالية:

المرحلة الأولى :جمع البيانات.

المرحلة الثانية :استكشاف البيانات وتحليلها.

المرحلة الثالثة :معالجة الصور وتجهيزها.

المرحلة الرابعة :تقسيم البيانات إلى Training / Validation / Testing.

المرحلة الخامسة :تدريب نماذج التصنيف واختبارها

المرحلة السادسة :تدريب نموذج Vision Transformer واختباره.

المرحلة السابعة :دمج الصور مع البيانات السريرية.


المرحلة الثامنة :استخدام MobileNet و YOLOv8 ضمن النظام التطبيقي.

المرحلة التاسعة :تقييم النماذج والمقارنة فيما بينها

المرحلة العاشرة :بناء واجهة الاستخدام باستخدام Streamlit.

المرحلة الحادية عشرة: تفسير النتائج باستخدام الخرائط الحرارية.

يوضح الشكل التالي بنية العمل:



الشكل 4.1 بنية العمل بشكل عام

4.4 مجموعة البيانات

تم استخدام مجموعة بيانات تحتوي على 4946 صورة موزعة على فئتين رئيسيتين:

عدد الصور	الفئة
2435	Normal
2511	OSCC
4946	المجموع

الجدول 4.1: توصيف الداتا سيت

4.5 تجهيز البيانات ومعالجتها

تم تنفيذ مجموعة من عمليات المعالجة قبل إدخال الصور إلى النماذج.

4.5.1 إنشاء DataFrame

تم إنشاء DataFrame يحتوي على:

- مسار الصورة .
- التصنيف الخاص بالصورة .

وبذلك أصبح بالإمكان التعامل مع الصور والتصنيفات بطريقة منظمة أثناء عمليات التدريب.

4.5.2 التحقق من البيانات

تم فحص البيانات والتحقق من وجود التكرارات والمشكلات المحتملة قبل البدء بالتدريب .

4.5.3 تغيير حجم الصور

تم تغيير حجم الصور بما يتناسب مع النموذج المستخدم.

فمثلاً، استخدم InceptionV3 حجم إدخال يبلغ:

299 × 299 pixels

بينما استخدمت النماذج الأخرى أحجام إدخال تتوافق مع بنيتها.

4.6 تقسيم البيانات

تم تقسيم مجموعة البيانات إلى ثلاث مجموعات:

• **Training Set:** 80%

• **Validation Set:** 10%

• **Testing Set:** 10%

المجموعة	الهدف
Training	تدريب النموذج وتحديث الأوزان
Validation	مراقبة أداء النموذج أثناء التدريب
Testing	قياس الأداء النهائي على بيانات لم يرها النموذج

الجدول 4.2: تقسيم البيانات والغرض منها

4.7 زيادة البيانات Data Augmentation

تم استخدام تقنيات Data Augmentation بهدف زيادة تنوع صور التدريب وتحسين قدرة النموذج على التعميم.

ومن التقنيات المستخدمة:

- Rotation.
- Zoom.
- Width Shift.
- Height Shift.
- Horizontal Flip.

تسمح هذه العمليات بإنشاء صور تدريبية متنوعة انطلاقًا من الصور الأصلية دون الحاجة إلى جمع صور جديدة.

ويهدف ذلك إلى تقليل احتمالية حدوث Overfitting وتحسين قدرة النموذج على التعامل مع صور جديدة.

4.8 تدريب نماذج التصنيف

تم استخدام مجموعة من النماذج المختلفة بهدف مقارنة أدائها في تصنيف الصور إلى:

Normal / OSCC

والنماذج الأساسية المستخدمة في المشروع هي:

1. AlexNet.
2. InceptionV3.
3. Vision Transformer (ViT).
4. MobileNetV2.

4.9 نموذج AlexNet

تم بناء نموذج AlexNet باستخدام طبقات CNN متتابعة لاستخراج الميزات من الصور.

يتكون النموذج المستخدم من مجموعة من:

- Conv2D.
- Batch Normalization.
- MaxPooling.
- Flatten.
- Dense.
- Dropout.

وفي الطبقة النهائية تم استخدام **Sigmoid** لإنتاج احتمالية الانتماء إلى فئة OSCC.

استخدم التدريب:


- Adam Optimizer.
- Learning Rate = 0.0001.
- Early Stopping.
- ReduceLROnPlateau.

وقد أظهر النموذج في الاختبار دقة بلغت حوالي 91.52% مع Recall حوالي 96.02%.

4.10 نموذج InceptionV3

تم استخدام InceptionV3 كنموذج قائم على Transfer Learning.

تم استخدام النموذج الأساسي لاستخراج الميزات من الصور، ثم تمت إضافة طبقات مخصصة للتصنيف.



الشكل 4.2 : نموذج cnn

4.11 نموذج Vision Transformer

تم إدخال Vision Transformer (ViT) إلى المشروع لتجربة بنية مختلفة عن CNN.

يعتمد ViT على تقسيم الصورة إلى أجزاء صغيرة تسمى Patches، ثم تحويل هذه الأجزاء إلى تمثيلات رقمية وإدخالها إلى Transformer Encoder.

A. ويختلف هذا النهج عن CNN في طريقة استخراج العلاقات والميزات من الصورة، إذ يعتمد على آلية

Self-Attention

4.12 النموذج متعدد الوسائط Multimodal ViT

وهذه نقطة مهمة جدًا في مشروعك ويجب إعطاؤها مساحة جيدة في التقرير.

بدل الاعتماد على الصورة فقط، تم دمج:

المعلومات البصرية

من صورة النسيج الفموي باستخدام ViT.

المعلومات السريرية

وتشمل:

- العمر .
- الجنس .
- التدخين .
- الكحول .
- مضغ التبغ .
- التاريخ العائلي .

هذه المتغيرات الستة معرفة فعليًا في الكود كمدخل للبيانات السريرية

وتتم عملية الدمج بين الميزات البصرية والسريرية قبل طبقات التصنيف النهائية

4.13 معالجة البيانات السريرية

قبل إدخال البيانات السريرية إلى النموذج، يتم تحويل المتغيرات إلى تمثيل رقمي مناسب للنموذج.

وبذلك يصبح لدينا متجه يمثل الخصائص السريرية للمريض.

ثم يتم دمج مع الميزات المستخرجة من الصورة.

4.14 نموذج MobileNetV2

تم استخدام MobileNet ضمن النظام التطبيقي كنموذج خفيف الوزن للتصنيف.

تكمُن أهمية MobileNet في تقليل العمليات الحسابية وعدد المعاملات مقارنة ببعض النماذج العميقة الأكبر، مما يجعله مناسباً للتطبيقات التي تتطلب سرعة أعلى وموارد حوسبة أقل.

ويظهر في التطبيق خيار استخدام MobileNet بصورة مستقلة أو ضمن التحليل الشامل

4.15 نموذج YOLOv8

على خلاف نماذج التصنيف التي تعطي قراراً للصورة ككل، تم استخدام YOLOv8 بهدف تنفيذ عملية الكشف البصري.

أي أن النموذج لا يكتفي بالسؤال:

هل الصورة مصابة أم طبيعية؟

بل يستطيع تحديد المناطق أو العناصر التي يتنبأ بها داخل الصورة باستخدام:

• Bounding Boxes.

- Class Labels.

- Confidence Scores.

ويظهر YOLOv8 ضمن النظام التطبيقي المستخدم للكشف عن المناطق المشبوهة.

4.16 آلية دمج النماذج

النظام النهائي لا يعتمد على نموذج واحد فقط.

بل يمكن استخدام النماذج لأغراض مختلفة:

وهذا يجعل النظام أكثر شمولاً من نموذج تصنيف تقليدي واحد

4.17 تقنيات تحسين التدريب

تم استخدام مجموعة من تقنيات تحسين التدريب، منها:

Early Stopping

إيقاف التدريب عند عدم تحسن أداء النموذج على بيانات التحقق، لتقليل Overfitting.

ReduceLROnPlateau

تقليل Learning Rate عندما يتوقف تحسن النموذج.

Dropout

تقليل الاعتماد المفرط على مجموعة معينة من الخلايا العصبية وتحسين التعميم.

Class Weights

يمكن استخدامها للتعامل مع الاختلاف في توزيع الفئات أثناء التدريب.

وقد ظهرت هذه الأساليب ضمن كود تدريب النماذج في المشروع

4.18 تقييم النماذج

تم تقييم النماذج باستخدام مجموعة من المقاييس.

Accuracy

تقيس نسبة التوقعات الصحيحة من إجمالي التوقعات.

Precision

تقيس مدى صحة الحالات التي صنفها النموذج على أنها إيجابية.

Recall

مهمة جدًا في التطبيقات الطبية، لأنها تقيس قدرة النموذج على اكتشاف الحالات المصابة فعليًا.

F1-Score

يمثل توازنًا بين Precision و Recall.

AUC

يستخدم لتقييم قدرة النموذج على التمييز بين الفئتين.

Confusion Matrix

توضح:

• True Positive.

• True Negative.

• False Positive.

• False Negative.

4.19 تفسير قرارات النموذج

لم يقتصر المشروع على إعطاء النتيجة النهائية، بل تمت إضافة وسائل للمساعدة في تفسير القرار.

لإظهار المناطق التي كان لها تأثير أكبر في قرار النموذج **Heatmaps / Grad-CAM** تم استخدام

:وهذا مهم في المجال الطبي لأن المستخدم لا يحتاج فقط إلى

OSCC = Positive

:بل من المفيد أيضًا معرفة

ما المنطقة التي اعتمد عليها النموذج في اتخاذ هذا القرار؟

ويظهر هذا التوجه ضمن النظام التطبيقي النهائي

4.20 واجهة النظام

تم تطوير واجهة استخدام باستخدام **Streamlit** بحيث يستطيع المستخدم:

1. رفع صورة الفحص .
2. إدخال البيانات السريرية .
3. اختيار طريقة التحليل .
4. تشغيل النموذج .
5. عرض نتيجة التصنيف .
6. عرض نتائج النماذج المختلفة .
7. عرض الكشف باستخدام YOLOv8.
8. عرض الخرائط الحرارية عند توفرها .

ويظهر في الكود وجود وضع **Comprehensive Analysis** الذي يجمع نتائج ViT و MobileNet

و YOLOv8، بالإضافة إلى خيارات منفصلة للتحليل متعدد الوسائط

4.21 خلاصة الفصل

تناول هذا الفصل المنهجية العملية المتبعة في بناء نظام الكشف عن سرطان الخلايا الحشوية الفموية. بدأت المنهجية بتجهيز مجموعة الصور وتصنيفها إلى Normal و OSCC، ثم إجراء عمليات المعالجة والتقسيم والتجهيز للتدريب.

بعد ذلك تم تدريب وتجربة مجموعة من النماذج المختلفة، شملت AlexNet و InceptionV3 و Vision Transformer، بالإضافة إلى نموذج Multimodal ViT الذي يجمع بين الصور والبيانات السريرية. كما تم دمج MobileNet و YOLOv8 ضمن النظام التطبيقي بهدف توفير تصنيف سريع وإمكانية الكشف البصري عن المناطق المشبوهة. وأخيراً تم بناء واجهة تفاعلية باستخدام Streamlit لعرض النتائج وتسهيل استخدام النظام.

الفصل الخامس:

معايير التقييم والنتائج

5.1 مقدمة

يستعرض هذا الفصل النتائج التي تم الحصول عليها من خلال تنفيذ المنهجية المقترحة للكشف عن سرطان الخلايا الحشرية الفموية (OSCC) تم تقييم النماذج المستخدمة باستخدام مجموعة من المقاييس الإحصائية، بالإضافة إلى تحليل مصفوفة الالتباس ومنحنيات التدريب والتحقق.

كما يتم في هذا الفصل عرض نتائج النماذج المختلفة ومناقشة نقاط القوة والاختلاف بينها، إضافة إلى توضيح كيفية الاستفادة من النموذج متعدد الوسائط والنماذج المستخدمة ضمن التطبيق النهائي.

5.2 إعداد التجارب

تم إجراء التجارب باستخدام مجموعة البيانات الخاصة بالمشروع، والتي تتكون من صور مصنفة إلى فئتين:

• Normal

• OSCC

تم تقسيم البيانات إلى مجموعات التدريب والتحقق والاختبار، ثم تدريب النماذج باستخدام بيانات التدريب ومراقبة الأداء على بيانات التحقق، بينما تم استخدام بيانات الاختبار لتقييم الأداء النهائي. تم استخدام مجموعة من تقنيات تحسين التدريب، مثل:

• Early Stopping.

• ReduceLROnPlateau.

• Model Checkpoint.

- Class Weights في نموذج ViT متعدد الوسائط .

وبالنسبة لـ ViT، يوضح الكود استخدام Adam بمعدل تعلم 5×10^{-5} ، مع Binary Cross-Entropy، وحساب Accuracy و AUC و Precision و Recall أثناء التدريب. كما تم استخدام Early Stopping و ReduceLROnPlateau وحفظ أفضل نموذج.

5.3 نتائج نموذج AlexNet

تم تقييم نموذج AlexNet باستخدام بيانات الاختبار، وحساب Accuracy و Recall و Precision و F1-Score بالإضافة إلى Confusion Matrix و Classification Report.

5.3.1 مصفوفة الالتباس

كانت مصفوفة الالتباس:

	Predicted Normal	Predicted OSCC
Actual Normal	212	32
Actual OSCC	10	241

الجدول 5.1: مصفوفة الالتباس

أي أن النموذج صنف:

- 212 صورة Normal بشكل صحيح .
- 241 صورة OSCC بشكل صحيح .

• 32 صورة Normal تم تصنيفها بالخطأ كـ OSCC.

• 10 صور OSCC تم تصنيفها بالخطأ كـ Normal.

ومن الناحية الطبية، يعد انخفاض عدد حالات **OSCC المصنفة على أنها Normal** أمراً مهماً، لأن هذه الحالات تمثل False Negative ، وقد تؤدي إلى عدم اكتشاف حالة مصابة

5.4 AlexNet.5.4 لنموذج Classification Report


يوضح تقرير التصنيف أداء النموذج لكل فئة:

الفئة	Precision	Recall	F1-Score	Support
Normal	0.95	0.87	0.91	244
OSCC	0.88	0.96	0.92	251
Accuracy			0.92	495

الجدول 5.2: تقرير النتائج لنموذج AlexNet

وتشير النتائج إلى أن النموذج حقق Recall مرتفعاً لفئة OSCC بلغ 96%، أي أنه تمكن من اكتشاف معظم الصور المصابة الموجودة في مجموعة الاختبار.

يوضح الشكل التالي مصفوفة الالتباس لنموذج AlexNet



الشكل 5.1: مصفوفة الالتباس لنموذج AlexNet

✓ 5.5 منحنيات تدريب AlexNet

✓ تم تسجيل Accuracy و Loss خلال مراحل التدريب والتحقق.

✓ يوضح منحنى Accuracy مدى تحسن قدرة النموذج على التصنيف مع زيادة عدد Epochs ، بينما

يوضح منحنى Loss مقدار الخطأ أثناء التدريب والتحقق.

✓ تم استخدام:

Adam Optimizer ✓


Learning Rate = 0.0001 ✓

Early Stopping ✓

ReduceLROnPlateau ✓

✓ عدد Epochs أقصى = 15

يوضح الشكل التالي منحنيات التعلم:




الشكل 5.2: منحنيات Accuracy و Loss للنموذج AlexNet

5.6 نتائج نموذج InceptionV3

تم استخدام نموذج InceptionV3 باعتباره أحد نماذج Transfer Learning المستخدمة في المشروع.

تم تقييم النموذج على بيانات الاختبار باستخدام المقاييس نفسها المستخدمة مع AlexNet.

يوضح الشكل InceptionV3: Confusion Matrix



الشكل 5.3 InceptionV3: Confusion Matrix

InceptionV3: Classification Report


Classification Report:

precision	recall	f1-score	support

Normal	0.86	0.88	0.87	244
OSCC	0.88	0.86	0.87	251
accuracy			0.87	495
macro avg	0.87	0.87	0.87	495
weighted avg	0.87	0.87	0.87	495

الجدول 5.3: تقرير النتائج لنموذج InceptionV3

يوضح الشكل منحنى Accuracy و Loss لنموذج InceptionV3



الشكل 5.4: منحنى Accuracy و Loss لنموذج InceptionV3

5.7 نتائج نموذج Vision Transformer (ViT)

تم تدريب نموذج Vision Transformer بهدف اختبار قدرة بنية Transformer على تصنيف الصور الطبية.

تم استخدام:

• Adam Optimizer.

Learning Rate = **0.00005**. •

Binary Cross-Entropy. •

Accuracy. •

AUC. •

Precision. •

Recall. •

Early Stopping. •

ReduceLROnPlateau. •

Model Checkpoint. •

Class Weights. •

وقد تم تدريب النموذج لمدة تصل إلى **20 Epochs** مع إمكانية إيقاف التدريب مبكرًا عند عدم تحسن

Validation Loss.

بعد التدريب تم إجراء التنبؤ على بيانات الاختبار باستخدام Threshold يساوي **0.5**، ثم حساب:

Accuracy. •

Precision. •

Recall. •


F1-Score. •

Confusion Matrix. •

Classification Report. •

5.7.1 مصفوفة الالتباس


يوضح الشكل Confusion Matrix لنموذج ViT :



الشكل 5.5 Confusion Matrix لنموذج ViT


5.7.2 منحنيات التدريب

يوضح الشكل Accuracy و Loss لنموذج ViT



الشكل 5.6 Accuracy و Loss لنموذج ViT

يوضح الشكل Precision و Recall للنموذج ViT :



الشكل 5.7 Precision و Recall للنموذج ViT

5.8 نتائج النموذج متعدد الوسائط Multimodal ViT

يُعد النموذج متعدد الوسائط من أهم أجزاء المشروع، لأنه لا يعتمد على الصورة فقط.

تم إدخال:

البيانات البصرية

الصورة المجهرية للمريض.

البيانات السريرية

- Age.
- Gender.
- Smoking.
- Alcohol.

• Chewing Tobacco.

• Family History.

ثم يتم دمج الميزات البصرية والسريية قبل عملية التصنيف.

في التطبيق، يتم تمرير الصورة والميزات السريية إلى نموذج ViT متعدد الوسائط وإنتاج احتمال الإصابة بـ OSCC.

5.9 نتائج نموذج MobileNet

 Classification Report:

	precision	recall	f1-score	support
Normal	0.9449	0.9836	0.9639	244
OSCC	0.9834	0.9442	0.9634	251
accuracy			0.9636	495
macro avg	0.9641	0.9639	0.9636	495
weighted avg	0.9644	0.9636	0.9636	495

الجدول 5.4: تقرير النتائج لنموذج MobileNet

تم استخدام MobileNet كنموذج خفيف الوزن داخل التطبيق بهدف توفير نموذج تصنيف سريع بالإضافة إلى النموذج متعدد الوسائط.


يقوم التطبيق بتحميل نموذج:

best_mobilenet.keras

ثم يقوم بإجراء preprocessing للصورة وإنتاج احتمالية الإصابة .


وفي وضع التشخيص الشامل يعرض التطبيق نتيجة MobileNet بجانب نتيجة ViT.

يوضح الشكل Confusion Matrix لنموذج MobileNet



الشكل 5.8 Confusion Matrix لنموذج MobileNet

يوضح الشكل Accuracy و Loss لنموذج MobileNet :



الشكل 5.9 Accuracy و Loss للنموذج MobileNet

5.10 نتائج YOLOv8

تم استخدام YOLOv8 بطريقة مختلفة عن نماذج التصنيف.

بينما يعطي ViT و MobileNet قرارًا مثل:

Normal / OSCC

فإن YOLOv8 يستخدم للكشف وتحديد المناطق أو العناصر المشبوهة داخل الصورة.

يقوم النموذج بإرجاع:

- Bounding Boxes.

- Classes.

- Confidence Scores.

ويقوم التطبيق بعرض الصورة بعد رسم نتائج الكشف عليها .


وقد تم تدريب YOLO باستخدام:

- YOLOv8n.

- Image Size = 640.

• Epochs = 50.

يوضح الشكل نتائج الكشف باستخدام YOLOv8



الشكل 5.10: نتائج الكشف باستخدام YOLOv8

5.11 نتائج النظام التطبيقي النهائي

تم تطوير واجهة تفاعلية تسمح للمستخدم باختيار عدة طرق للتحليل:

1. التشخيص الشامل :

○ ViT.

○ MobileNet.

○ YOLOv8.


2. Multimodal ViT + Heatmap

3. MobileNet + Heatmap

4. YOLOv8 Detection & Localization

في وضع التشخيص الشامل، يتم عرض نتيجة ViT و MobileNet، بالإضافة إلى نتيجة YOLOv8 الخاصة بالكشف البصري

يوضح الشكل نتائج التشخيص الشامل



الشكل 5.11 نتائج التشخيص الشامل

5.14 التفسير البصري للنتائج

يوفر التطبيق خريطة حرارية لمساعدة المستخدم على فهم المناطق البصرية التي تم إبرازها أثناء التحليل.

وتُعرض الخريطة الحرارية مع الصورة الأصلية بهدف توفير تمثيل بصري إضافي لنتيجة النموذج.

وهذا يساعد على جعل النظام أكثر قابلية للفهم، خصوصًا في التطبيقات الطبية التي لا يكفي فيها عرض التصنيف النهائي فقط.

5.15 نقاط القوة

يمكن تلخيص نقاط قوة النظام في:

1. استخدام أكثر من نموذج للتصنيف والمقارنة .
2. استخدام Vision Transformer إلى جانب CNN.
3. دمج الصور مع البيانات السريرية .
4. وجود نموذج خفيف الوزن MobileNet.
5. إضافة Object Detection باستخدام YOLOv8.
6. توفير واجهة استخدام تفاعلية .
7. توفير تمثيل بصري للنتائج .
8. استخدام عدة مقاييس لتقييم النماذج.

الفصل السابع: الخلاصة و التوصيات

6.1 مقدمة

تناول هذا المشروع تطوير نظام ذكي يعتمد على تقنيات الذكاء الاصطناعي والتعلم العميق للمساعدة في الكشف عن سرطان الخلايا الحشفية الفموية (Oral Squamous Cell Carcinoma – OSCC) من خلال تحليل الصور المجهرية للأنسجة الفموية.

اعتمد النظام على مجموعة من النماذج والخوارزميات الحديثة، شملت الشبكات العصبية التلافيفية (CNN) ، ونماذج التعلم بالنقل (Transfer Learning) ، ونموذج Vision Transformer (ViT) ، بالإضافة إلى التعلم متعدد الوسائط الذي يجمع بين الصور الطبية والبيانات السريرية.

كما تم دمج نموذج MobileNet كنموذج خفيف الوزن، ونموذج YOLOv8 للكشف عن المناطق المشبوهة، بالإضافة إلى تقنيات التفسير البصري للمساعدة في فهم قرارات النماذج.

6.2 الخلاصة

تم خلال هذا المشروع تصميم وتنفيذ نظام متكامل يهدف إلى دعم عملية الكشف عن سرطان الفم باستخدام تقنيات الذكاء الاصطناعي.

بدأ العمل بتجهيز مجموعة البيانات وتصنيف الصور إلى فئتين رئيسيتين:

• Normal

• OSCC

ثم تمت معالجة الصور وتجهيزها بما يتناسب مع متطلبات النماذج المستخدمة، وتقسيم البيانات إلى مجموعات التدريب والتحقق والاختبار.

بعد ذلك تم تطبيق عدة نماذج مختلفة بهدف دراسة قدرة كل منها على التعامل مع صور الأنسجة الفموية.

شملت النماذج المستخدمة:

- AlexNet
- InceptionV3
- Vision Transformer (ViT)
- Multimodal ViT
- MobileNet
- YOLOv8

وقد أظهر نموذج AlexNet ، وفق النتائج التجريبية الموثقة في المشروع، أداءً جيدًا في تصنيف الصور، حيث بلغت دقة التصنيف 91.52%، بينما بلغ Recall حوالي 96.02%، و Precision حوالي 88.28%، و F1-Score حوالي 91.98%.

وتكتسب قيمة Recall أهمية خاصة في هذه الحالة بسبب طبيعة التطبيق الطبي، إذ إن اكتشاف أكبر عدد ممكن من الحالات المصابة يساعد على تقليل احتمال تصنيف الحالات السرطانية على أنها حالات طبيعية.

كما تم الانتقال من الاعتماد على الصور وحدها إلى استخدام Multimodal Learning، حيث تم دمج الميزات المستخرجة من الصور المجهريّة مع البيانات السريرية للمريض، والتي تشمل العمر والجنس والتدخين والكحول ومضغ التبغ والتاريخ العائلي.

ومن ناحية أخرى، أتاح استخدام Vision Transformer تجربة بنية حديثة تختلف عن الشبكات العصبية التلافيفية التقليدية، بينما وفر MobileNet خيارًا أخف من ناحية الموارد الحسابية، وتم استخدام YOLOv8 لإضافة جانب الكشف وتحديد المناطق أو العناصر داخل الصور.

وأخيرًا، تم دمج هذه المكونات في تطبيق تفاعلي باستخدام Streamlit، بحيث يستطيع المستخدم رفع الصورة وإدخال البيانات السريرية واختيار طريقة التحليل وعرض نتائج النماذج المختلفة، بالإضافة إلى الخرائط الحرارية ونتائج الكشف عند توفرها.

وبذلك لم يقتصر المشروع على بناء نموذج تصنيف واحد، وإنما تم تطوير نظام متعدد المكونات يجمع بين التصنيف، والبيانات السريرية، والكشف البصري، والتفسير البصري للنتائج.

6.3 أهم ما تم تحقيقه

يمكن تلخيص أهم الإنجازات التي تم الوصول إليها في النقاط التالية:

1. بناء نظام للكشف عن OSCC باستخدام التعلم العميق .
2. تجهيز ومعالجة مجموعة صور مصنفة إلى Normal و OSCC.
3. تطبيق نموذج **AlexNet** لتصنيف الصور .
4. استخدام **InceptionV3** والاستفادة من Transfer Learning.
5. تطبيق **Vision Transformer** لتحليل الصور الطبية .
6. تطوير نموذج **Multimodal ViT** يجمع بين الصور والبيانات السريرية .
7. استخدام **MobileNet** كنموذج خفيف الوزن .
8. استخدام **YOLOv8** للكشف عن المناطق أو العناصر المشبوهة .
9. تطبيق تقنيات مثل Early Stopping و ReduceLROnPlateau و Dropout لتحسين عملية التدريب .
10. استخدام مقاييس متعددة لتقييم النماذج، مثل Accuracy و Precision و Recall و F1-Score و Confusion Matrix.
11. إضافة وسائل للتفسير البصري مثل Heatmaps.
12. تطوير واجهة تفاعلية باستخدام Streamlit.

6.4 التوصيات

بناءً على النتائج والتجارب التي تم تنفيذها، يمكن تقديم مجموعة من التوصيات لتطوير النظام وتحسين استخدام تقنيات الذكاء الاصطناعي في الكشف عن سرطان الفم.

1.زيادة حجم قاعدة البيانات

ينصح باستخدام عدد أكبر من الصور المجهرية، بحيث تشمل حالات مختلفة ومصادر متعددة، مما يساعد النماذج على تعلم أنماط أكثر تنوعًا وتحسين قدرتها على التعميم.

2.تنوع مصادر البيانات

من الأفضل ألا تعتمد عملية التدريب على مصدر واحد للصور، بل استخدام بيانات من مستشفيات ومختبرات ومراكز مختلفة، بهدف تقليل تأثير اختلاف الأجهزة وطرق التصوير.

3.تحسين جودة الصور

يمكن استخدام تقنيات متقدمة لتحسين الصور وإزالة التشويش وتصحيح الإضاءة والتباين قبل إدخالها إلى النماذج.

4.زيادة البيانات السريية

يمكن توسيع البيانات السريية المستخدمة في النموذج متعدد الوسائط بإضافة متغيرات طبية أخرى ذات علاقة بسرطان الفم، بشرط توفرها بشكل موثوق.

5.الاعتماد على مقاييس طبية متعددة

لا ينبغي الاعتماد على Accuracy فقط، وخاصة في التطبيقات الطبية، بل يجب التركيز أيضًا على:

• Recall.

• Precision.

• Specificity.

• F1-Score.

• AUC.

6. تحسين قابلية تفسير النموذج

ينصح بتطوير تقنيات Explainable AI بحيث يستطيع الطبيب معرفة المناطق والميزات التي أثرت بشكل أكبر في قرار النموذج.

7. اختبار النظام من قبل مختصين

قبل استخدام النظام في بيئة سريرية حقيقية، يجب إجراء اختبارات ومقارنات مع تقييم أطباء وأخصائيي علم الأمراض.

8. الحفاظ على الخصوصية

ينبغي التعامل مع البيانات الطبية وفق سياسات الخصوصية وحماية بيانات المرضى، وإزالة أي معلومات تعريفية غير ضرورية.

6.5 الأعمال المستقبلية

يمكن تطوير المشروع مستقبلاً من خلال مجموعة من الاتجاهات.

6.5.1 استخدام نماذج Transformer أكثر تطوراً

يمكن تجربة نماذج أحدث من Vision Transformer ومقارنتها مع النماذج الحالية، مثل النماذج التي تعتمد على آليات Attention أكثر تطوراً.

6.5.2 تطوير النموذج متعدد الوسائط

يمكن توسيع Multimodal Learning ليشمل مصادر إضافية للبيانات، مثل:

- الصور المجهرية .
 - البيانات السريرية .
 - نتائج الفحوصات المخبرية .
 - التاريخ الطبي .
 - بيانات إضافية متعلقة بالمريض .
- وبذلك يمكن بناء نموذج أكثر شمولاً.

6.5.3 استخدام نماذج الكشف والتقسيم

يمكن تطوير YOLOv8 إلى نظام أكثر دقة لتحديد المناطق السرطانية، أو دمجها مع نماذج Image Segmentation لتحديد حدود الخلايا أو الأنسجة المصابة بدقة أكبر.

6.5.4 تطوير نظام دعم قرار طبي

يمكن تطوير النظام من مجرد إعطاء:

Normal / OSCC

إلى نظام دعم قرار يعرض:

- احتمالية الإصابة .
 - مستوى الثقة .
 - المناطق المشبوهة .
 - المعلومات السريرية ذات الصلة .
 - التفسير البصري للقرار .
- مع التأكيد على أن النظام يكون أداة مساعدة للطبيب وليس بديلاً عنه.

6.5.5 تطبيق النظام على الأجهزة المحمولة

يمكن الاستفادة من نموذج MobileNet لتطوير نسخة تعمل على:

- الهواتف الذكية .
 - الأجهزة اللوحية .
 - الأجهزة ذات الموارد المحدودة .
- وهذا قد يجعل النظام أكثر قابلية للاستخدام في البيئات التي لا تتوفر فيها أجهزة حاسوب قوية.

6.5.6 إجراء اختبار خارجي للنظام

من أهم التطويرات المستقبلية اختبار النموذج على External Dataset لم يتم استخدامه أثناء التدريب أو اختيار النموذج، وذلك للتحقق من قدرة النظام على التعميم على صور جديدة تماماً.

6.5.7 تطوير واجهة النظام

يمكن مستقبلاً تطوير واجهة Streamlit الحالية وتحويلها إلى نظام أكثر تكاملاً، مع:

- إدارة المستخدمين .
- حفظ نتائج الحالات .
- إنشاء تقارير PDF.
- عرض سجل الفحوصات .
- دعم عدة لغات .
- تحسين تجربة المستخدم.

6.7 الخلاصة النهائية

في ختام هذا المشروع، تم تطوير نظام يعتمد على تقنيات الذكاء الاصطناعي الحديثة بهدف المساعدة في الكشف عن سرطان الخلايا الحشوية الفموية من الصور المجهرية.

وقد جمع المشروع بين عدة اتجاهات في الذكاء الاصطناعي، بدءاً من الشبكات العصبية التلافيفية ونماذج Transfer Learning، وصولاً إلى Vision Transformer والتعلم متعدد الوسائط، بالإضافة إلى استخدام MobileNet و YOLOv8 وتقنيات Explainable AI.

وأظهرت النتائج التجريبية إمكانية استخدام هذه التقنيات في تحليل صور الأنسجة الفموية والمساعدة في التمييز بين الحالات الطبيعية والمصابة.

ويُعد دمج الصورة المجهرية مع البيانات السريرية من أهم الجوانب التي تميز النظام، حيث يوفر منظوراً أكثر شمولاً مقارنة بالاعتماد على الصورة وحدها.

وفي النهاية، يمثل المشروع خطوة بحثية نحو تطوير أنظمة ذكية يمكن أن تساعد المتخصصين في عملية الكشف المبكر عن سرطان الفم، مع إمكانية تطوير النظام مستقبلاً من خلال زيادة حجم البيانات، وتحسين النماذج، وإجراء اختبارات خارجية، والتعاون مع المختصين في المجال الطبي.

[1]

Al-Dwairi, Z. N., Al-Hadidi, A., & others. **Histopathological Image Analysis for Oral Cancer Classification by Support Vector Machine.** 2021.

[2]

Sanjeewa, K. et al. **Application and Performance of Artificial Intelligence (AI) in Oral Cancer Diagnosis and Prediction Using Histopathological Images: A Systematic Review.** 2024.

[3]

Oral Squamous Cell Carcinoma Detection Using EfficientNet on Histopathological Images. 2024.

[4]

Clinically Applicable Histopathological Diagnosis System for Gastric Cancer Detection Using Deep Learning. 2020.

[5]

Machine Learning Techniques Used for the Histopathological Image Analysis of Oral Cancer – A Review. 2020

[6]

Histopathologic Oral Cancer Prediction Using Oral Squamous Cell Carcinoma Biopsy Empowered with Transfer Learning. 2022.

[7]

Krizhevsky, A., Sutskever, I., & Hinton, G. E. **ImageNet Classification with Deep Convolutional Neural Networks.** *Advances in Neural Information Processing Systems (NeurIPS)*, 2012, pp. 1097–1105.

[8]

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. **Going Deeper with Convolutions**. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 1–9.

[9]

Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. **An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale**. *International Conference on Learning Representations (ICLR)*, 2021.

[10]

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. **MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications**. 2017.

[11]

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. **You Only Look Once: Unified, Real-Time Object Detection**. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[12]

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. **Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization**. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.

[13]

Goodfellow, I., Bengio, Y., & Courville, A. **Deep Learning**. MIT Press, 2016.

[14]

Chollet, F. **Deep Learning with Python**. 2nd Edition, Manning Publications, 2021

[15]

Abadi, M., Agarwal, A., Barham, P., et al. **TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems**. 2016.

[16]

McKinney, W. **Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython**. O'Reilly Media.

[17]

Bradski, G. **The OpenCV Library**. *Dr. Dobbs's Journal of Software Tools*, 2000.

[18]

Hunter, J. D. **Matplotlib: A 2D Graphics Environment**. *Computing in Science & Engineering*, 9(3), 90–95, 2007.



Syrian Private University

Faculty of Information Engineering

Department of Artificial Intelligence

& Data Science

Oral Cancer Detection Using Machine Learning Techniques

Prepared by :

Layth alabraham

Supervised by :

Dr.Majida AlBakoor

Eng.Farah Fares

year

(2025-2026)